APUNTES PROYECTO DE INVESTIGACIÓN

PROFESOR: DAVID SOSSA.
AYUDANTE: JUAN I. RIQUELME.

Definición 1. El primer ángulo principal entre un par de s.v P y Q se define por:

$$\cos\theta_1 := \text{máx}\{\langle u, v\rangle \mid u \in P, v \in Q, \text{ y } \|u\| = \|v\| = 1\}, \quad (i)$$

y dado que la función coseno es decreciente en $[0, \pi]$, podemos pensar en θ_1 como un ángulo mínimo entre los espacios P y Q. Un par (u_1, v_1) que logra el ángulo mínimo θ_1 **se llama un par de vectores principales**.

Definición 2. Dos puntos u y v en un conjunto compacto K son **antípodas** si son "diametralmente opuestos", lo que significa que $\|u - v\|$ alcanza el diámetro del conjunto K,

$$\text{diam}(K) := \text{máx}\{\|u - v\| \mid u, v \in K\}.$$

El diámetro de un cono convexo cerrado no está definido, porque los conos son no acotados. Sin embargo, si consideramos solo sus elementos de norma unitaria, entonces estos forman un conjunto compacto y podemos formular el problema

$$\max \|u - v\| \text{ sujeto a } u, v \in K \text{ y } \|u\| = \|v\| = 1.$$

Maximizar $\|u - v\|^2$ es equivalente a minimizar $\langle u, v\rangle$, lo cual a su vez es equivalente a maximizar un ángulo.

Definición 3. Se define el ángulo máximo de un cono convexo cerrado K como

$$\theta_{\max}(K) := \sup\{\arccos\langle u, v\rangle \mid u, v \in K \text{ y } \|u\| = \|v\| = 1\}. \quad (ii)$$

y notar que

$$\arccos\langle u, v\rangle = \theta_{\max}(K) \Longleftrightarrow \|u - v\| = \text{diam}(\{x \in K \mid \|x\| = 1\}).$$

Proposición 1. *Sea K un cono convexo poliédrico con conjunto generador de norma unitaria G. Si $\theta_{max}(K) \leq \pi/2$ y si $g_1, g_2 \in G$ forman el mayor ángulo dentro de G, entonces (g_1, g_2) es un par antipodal de K.*

0.1. 2 Conos. *Se V denotará un espacio de Hilbert real de dimensión finita. Un subconjunto no vacío K de V es un cono si $\alpha K \subseteq K$ para todo $\alpha \geq 0$. Un cono es convexo y cerrado como subconjunto de V, y la envoltura cónica de un subconjunto no vacío X de V es un cono convexo,*

$$cone(X) := \left\{\sum_{i=1}^{m} \alpha_i x_i \mid x_i \in X, \alpha_i \geq 0, m \in \mathbb{N}\right\}.$$

Date: 26 de abril de 2026.

Si cone$(G) = K$, entonces G genera K y los elementos de G son generadores de K. Si un conjunto finito genera K, entonces K es ***poliédrico****. Todos los conos convexos poliédricos son cerrados. Nótese que para $G \neq \{0\}$ tenemos*

$$cone(G) = cone\left(\frac{g}{\|g\|} \mid g \in G, g \neq 0\right),$$

y que, por lo tanto, no se pierde generalidad si insistimos en generadores de norma unitaria. Para mayor comodidad, denotamos la esfera unitaria en V como $\mathbb{S}(V)$. Si K es un subconjunto de V, entonces el cono dual de K es

$$K^* := \{y \in V \mid \langle x, y\rangle \geq 0 \text{ para todo } x \in K\}.$$

Si K está contenido en K^*, entonces K es subdual. Adoptamos la definición estándar del ángulo θ entre dos vectores u y v en un espacio de Hilbert.

El conjunto de ***conos admisibles*** *en V es:*

$$\mathcal{C}(V) := \{K \mid K \text{ es un cono convexo cerrado en } V \text{ y } K \notin \{\{0\}, V\}\}.$$

Si $P, Q \in \mathcal{C}(V)$ son admisibles, entonces el ángulo máximo entre P y Q es

$$\sup\{\arccos\langle u, v\rangle \mid u \in P \cap \mathbb{S}(V), v \in Q \cap \mathbb{S}(V)\}. \quad (1)$$

Definición 4. Si $P, Q \in \mathcal{C}(V)$, entonces el ángulo máximo entre P y Q es

$$\Theta(P, Q) := \arccos(\text{mín}\{\langle u, v\rangle \mid u \in P \cap \mathbb{S}(V), v \in Q \cap \mathbb{S}(V)\}).$$

Si $\arccos\langle \overline{u}, \overline{v}\rangle = \Theta(P, Q)$ para algún $\overline{u} \in P \cap \mathbb{S}(V)$ y $\overline{v} \in Q \cap \mathbb{S}(V)$, entonces $(\overline{u}, \overline{v})$ es un par antípoda de (P, Q). Abreviamos $\Theta(K, K)$ como $\Theta(K)$.

los pares de puntos que satisfacen las condiciones necesarias. Se llaman **pares críticos**

Definición 5. Si $P, Q \in \mathcal{C}(V)$, entonces (u, v) es un par crítico de (P, Q) si

- $u \in P \cap \mathbb{S}(V)$,
- $v \in Q \cap \mathbb{S}(V)$,
- $v - \langle u, v\rangle u \in P^*$, y
- $u - \langle u, v\rangle v \in Q^*$

En ese caso, $\arccos\langle u, v\rangle$ es un ángulo crítico de (P, Q). El conjunto de todos estos ángulos es el espectro angular de (P, Q), y se denota por $\Gamma(P, Q)$.

corresponde al par $(u, v) = (G_I\xi, H_J\eta)$.

1. El Método de Newton Semismooth

1.1. Derivada Generalizada.

Teorema 1. *(Rademacher) Supongamos que la función $F : \mathbb{R}^n \to \mathbb{R}^m$ es localmente Lipschitz continua. Entonces F es diferenciable casi en todas partes.*

En lo que sigue, $\Omega_F \subset \mathbb{R}^n$ denotará el conjunto de todos los puntos donde F es diferenciable, es decir,

$$\Omega_F := \{x \in \mathbb{R}^n : F \text{ es diferenciable en } x\}.$$

Definición 6. Sea A un subconjunto de $\mathbb{R}^n$. La envoltura convexa de A, denotada por $\mathrm{co}(A)$, está dada de la siguiente manera:

$$\mathrm{co}(A) := \left\{ \sum_{i=1}^{\ell} \lambda_i a_i : \{a_1, \ldots, a_\ell\} \subseteq A, \{\lambda_1, \ldots, \lambda_\ell\} \subseteq \mathbb{R} \text{ tal que } \lambda_i \geq 0, \sum_{i=1}^{\ell} \lambda_i = 1 \right\}.$$

En otras palabras, $\mathrm{co}(A)$ es el conjunto convexo más pequeño que contiene a A.

Definición 7. Sea $F : \mathbb{R}^n \to \mathbb{R}^m$ una función localmente Lipschitz continua. El *B-subdiferencial* de F en x, denotado por $\partial_B F(x)$, está dado por

$$\partial_B F(x) := \{G \in \mathbb{M}_{m\times n} : \exists \{x_k\} \subset \Omega_F \text{ tal que } x_k \to x \text{ y } J_F(x_k) \to G\}.$$

La *derivada generalizada* de F en $x \in \mathbb{R}^n$, denotada por $\partial F(x)$, está dada por

$$\partial F(x) := \mathrm{co}(\partial_B F(x)).$$

Proposición 2. *Sea $F : \mathbb{R}^n \to \mathbb{R}^m$ una función continuamente diferenciable en $x \in \mathbb{R}^n$. Entonces,*

$$\partial F(x) = \{JF(x)\}.$$

Ejemplo 1. Función valor absoluto

Consideremos la función $f : \mathbb{R} \to \mathbb{R}$ definida por $f(x) = |x|$.

f es diferenciable en todo $\mathbb{R} \setminus \{0\}$ y en este caso la derivada generalizada coincide con la derivada usual. Es decir, uno tiene $\partial f(x) = \{f'(x)\}$ donde

$$f'(x) = \begin{cases} 1 & \text{si } x > 0 \\ -1 & \text{si } x < 0 \end{cases}$$

Ahora calculemos la derivada generalizada de f en $x = 0$. Notemos que si tomamos una sucesión $\{x_n\}$ donde f es diferenciable (es decir $x_n \neq 0$) tal que $x_n \to 0$, entonces la sucesión $f'(x_n)$ si es convergente, convergerá a 1 o a -1. Por ejemplo, tomemos las sucesiones $\{x_n\}, \{y_n\}$ definidas como

$$x_n = \frac{1}{n}, \quad y_n = -\frac{1}{n}.$$

Notemos que $x_n \to 0$ y $y_n \to 0$ y además f es diferenciable en x_n e y_n cuyas derivadas son:

$$f'(x_n) = 1, \quad f'(y_n) = -1, \quad \text{para todo } n \in \mathbb{N}.$$

Entonces,

$$\lim_{n\to\infty} f'(x_n) = 1, \quad \lim_{n\to\infty} f'(y_n) = -1.$$

Por lo tanto,

$$\partial f(0) = \mathrm{co}\{-1, 1\} = [-1, 1].$$

Ejemplo 2. Consideremos la función $F : \mathbb{R}^3 \to \mathbb{R}^3$ definida por

$$F(x) := \begin{pmatrix} |u| + |v| - 1 \\ uv - 1 + \text{máx}\{0, w\} \\ u + e^v - 2w \end{pmatrix}$$

Donde $x = (u, v, w)$. Observemos que se cumple $\text{máx}\{0, w\} = \frac{1}{2}(|w| + w)$, entonces la función F puede escribirse como

$$F(x) = \begin{pmatrix} |u| + |v| - 1 \\ uv - 1 + \frac{1}{2}(|w| + w) \\ u + e^v - 2w \end{pmatrix}$$

Podemos ver que F no es diferenciable en el conjunto $\mathcal{N} = \{(u,v,w) \in \mathbb{R}^3 : (u=0) \vee (v=0) \vee (w=0)\}$. En puntos donde F es diferenciable, el Jacobiano de F está dado por

$$JF(x) = \begin{pmatrix} \frac{u}{|u|} & \frac{v}{|v|} & 0 \\ v & u & \frac{1}{2}\left(\frac{w}{|w|}+1\right) \\ 1 & e^v & -2 \end{pmatrix}$$

Nos proponemos a calcular la derivada generalizada de F en el punto $x^* := (1,0,1)$: Sea $\{x_n := (u_n, v_n, w_n)\}$ una sucesión de puntos donde F es diferenciable y que converge a $(1,0,1)$. Dado que $u_n \to 1$ y $w_n \to 1$, podemos observar que para n suficientemente grande $u_n > 0$ y $w_n > 0$. Entonces solo debemos analizar los casos $v_n > 0$ y $v_n < 0$.

Si $v_n > 0$ entonces tenemos

$$JF(x_n) = \begin{pmatrix} 1 & 1 & 0 \\ v_n & u_n & 1 \\ 1 & e^{v_n} & -2 \end{pmatrix}$$

Entonces, en este caso, cuando $x_n \to x^*$ tenemos que

$$JF(x_n) \to \begin{pmatrix} 1 & 1 & 0 \\ 0 & 1 & 1 \\ 1 & 1 & -2 \end{pmatrix}$$

Si $v_n < 0$ entonces tenemos

$$JF(x_n) = \begin{pmatrix} 1 & -1 & 0 \\ v_n & u_n & 1 \\ 1 & e^{v_n} & -2 \end{pmatrix}$$

Entonces, en este caso, cuando $x_n \to x^*$ tenemos que

$$JF(x_n) \to \begin{pmatrix} 1 & -1 & 0 \\ 0 & 1 & 1 \\ 1 & 1 & -2 \end{pmatrix}$$

Esto implica que

$$\partial F(1,0,1) = \operatorname{co}\left\{ \begin{pmatrix} 1 & 1 & 0 \\ 0 & 1 & 1 \\ 1 & 1 & -2 \end{pmatrix}, \begin{pmatrix} 1 & -1 & 0 \\ 0 & 1 & 1 \\ 1 & 1 & -2 \end{pmatrix} \right\}$$

$$= \left\{ \lambda \begin{pmatrix} 1 & 1 & 0 \\ 0 & 1 & 1 \\ 1 & 1 & -2 \end{pmatrix} + (1-\lambda) \begin{pmatrix} 1 & -1 & 0 \\ 0 & 1 & 1 \\ 1 & 1 & -2 \end{pmatrix} : 0 \le \lambda \le 1 \right\}$$

$$= \left\{ \begin{pmatrix} 1 & 2\lambda - 1 & 0 \\ 0 & 1 & 1 \\ 1 & 1 & -2 \end{pmatrix} : 0 \le \lambda \le 1 \right\}$$

Definición 8. Sea $F : \mathbb{R}^n \to \mathbb{R}^m$ una función. Se dice que F es semismooth en $x \in \mathbb{R}^n$ si se cumplen las siguientes condiciones:

1. F es localmente Lipschitz continua en x.
2. F es direccionalmente diferenciable en x.
3. Para todo $\varepsilon > 0$ existe $\delta > 0$ tal que si $\|d\| < \delta$, entonces

$$\|F(x+d) - F(x) - Vd\| \le \varepsilon \|d\|, \quad \text{para todo } V \in \partial F(x+d).$$

Se dice que F es semismooth en $\mathbb{R}^n$ si F es semismooth en todo $x \in \mathbb{R}^n$.

1.2. El Método de Newton Semismooth. Sea $F : \mathbb{R}^n \to \mathbb{R}^n$. El Método de Newton Semismooth (MNS) para resolver el sistema cuadrado de ecuaciones $F(x) = 0$, está dado de la siguiente manera:

Método MNS.

Paso 0. Definir un $x_0 \in \mathbb{R}^n$.
Paso 1. Iteración: Determinar la solución del sistema lineal

$$V_{x_k} d_k = -F(x_k)$$

donde $V_{x_k} \in \mathbb{M}_{n\times n}$ es cualquier elemento de $\partial F(x_k)$.
Paso 2. Actualizar $x_{k+1} = x_k + d_k$, hacer $k \leftarrow k+1$ e ir al Paso 1.

Observemos que para que la iteración $\{x_k\}$ generada por el método MNS esté bien definida, debemos tener que V_{x_k} sea invertible para que el sistema lineal del Paso 1 tenga solución. De este modo la iteración estará dada por

$$x_{k+1} = x_k - V_{x_k}^{-1} F(x_k).$$

Ejemplo 3. resolveremos el sistema no lineal que está dado por

$$F(x) := \begin{pmatrix} |u| + |v| - 1 \\ uv - 1 + \text{máx}\{0, w\} \\ u + e^v - 2w \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix}$$

donde $x = (u, v, w)$.

Como vimos en ejemplos anteriores F puede escribirse como

$$F(x) = \begin{pmatrix} |u| + |v| - 1 \\ uv - 1 + \frac{1}{2}(|w| + w) \\ u + e^v - 2w \end{pmatrix}$$

podemos ver que el punto $x^* = (1, 0, 1)$ es una solución del sistema, es decir $F(x^*) = 0$.

Ahora veamos que los elementos de $\partial F(x^*)$ son matrices invertibles. En el Ejemplo 16 se ha demostrado que

$$\partial F(1, 0, 1) = \left\{ \begin{pmatrix} 1 & 2\lambda - 1 & 0 \\ 0 & 1 & 1 \\ 1 & 1 & -2 \end{pmatrix} : 0 \le \lambda \le 1 \right\}$$

Calculando el determinante de estas matrices tenemos que

$$\det \begin{pmatrix} 1 & 2\lambda - 1 & 0 \\ 0 & 1 & 1 \\ 1 & 1 & -2 \end{pmatrix} = 2\lambda - 4$$

Notemos que $2\lambda - 4 \neq 0$ para todo $\lambda \in [0, 1]$. Entonces las matrices de $\partial F(x^*)$ tienen determinante no nulo, lo que implica que las matrices de $\partial F(x^*)$ son invertibles.

Ya que hemos verificado las hipótesis del Teorema 23, entonces deberá existir un x_0 suficientemente cercano a x^* tal que la iteración $\{x_k\}$ generada por el método SNM converge superlinealmente a x^*. Veamos este hecho haciendo cuatro iteraciones:

Punto inicial. Tomemos como punto inicial $x_0 = \left(\frac{1}{2}, \frac{1}{2}, \frac{1}{2}\right)$. Claramente este punto inicial no está tan lejos de $x^* = (1, 0, 1)$.

Iteración. Notemos que F es diferenciable en x_0 y entonces $\partial F(x_0) = \{JF(x_0)\}$. Ahora debemos resolver el sistema

$$JF(x_0)d_0 = -F(x_0),$$

que en este caso es

$$\begin{pmatrix} 1 & 1 & 0 \\ \frac{1}{2} & \frac{1}{2} & 1 \\ 1 & e^{\frac{1}{2}} & -2 \end{pmatrix} d_0 = -\begin{pmatrix} 0 \\ -\frac{1}{4} \\ e^{\frac{1}{2}} - \frac{1}{2} \end{pmatrix}$$

Resolviendo tal sistema lineal obtenemos:

$$d_0 = (1, -1, \frac{1}{4}).$$

Entonces la iteración x_1 es igual a:

$$x_1 = x_0 + d_0 = \left(\frac{3}{2}, -\frac{1}{2}, \frac{3}{4}\right).$$

La iteración x_1 no es una buena aproximación a la solución x^*. Esto se puede ver cuando calculamos $\|F(x_1)\| = 1{,}54$ el cual no está cerca a cero. Entonces debemos calcular las siguientes iteraciones. En el Cuadro 1 se calculan los elementos necesarios para calcular las iteraciones x_2, x_3, x_4. Notemos que F es diferenciable en x_1, x_2, x_3 y por lo tanto no hizo falta usar la derivada generalizada. La iteración $x_4 = (1{,}00, 0{,}00, 1{,}00)$ es una muy buena aproximación a la solución x^*.

	$k = 1$	$k = 2$	$k = 3$
x_k	$(3/2,\ -1/2,\ 3/4)$	$(0.89,\ -0.11,\ 0.86)$	$(1.01,\ 0.01,\ 1.01)$
$J_F(x_k)$	$\begin{pmatrix} 1 & -1 & 0 \\ -1/2 & 3/2 & 1 \\ 1 & e^{1/2} & -2 \end{pmatrix}$	$\begin{pmatrix} 1 & -1 & 0 \\ -0.11 & 0.89 & 1 \\ 1 & 0.90 & -2 \end{pmatrix}$	$\begin{pmatrix} 1 & 1 & 0 \\ 0.01 & 1.01 & 1 \\ 1 & 1.01 & -2 \end{pmatrix}$
$F(x_k)$	$(1,\ -1,\ e^{-1/2})$	$(0,\ -0.24,\ 0.05)$	$(0.02,\ 0.02,\ 0.01)$
d_k	$(0.62,\ 0.39,\ 0.11)$	$(0.12,\ 0.12,\ 0.14)$	$(-0.01,\ -0.01,\ -0.01)$
x_{k+1}	$(0.89,\ -0.11,\ 0.86)$	$(1.01,\ 0.01,\ 1.01)$	$(1.00,\ 0.00,\ 1.00)$
$\|F(x_{k+1})\|$	0.24	0.02	9.5×10^{-5}

FIGURA 1. Cálculo de las iteraciones x_2, x_3 y x_4

1.3. Problemas de Complementaridad.

Definición 9. Se dice que dos vectores $x, y \in \mathbb{R}^n$ son complementarios si satisfacen

$$\begin{cases} x \geq 0, \\ y \geq 0, \\ \langle x, y \rangle = 0. \end{cases} \tag{27}$$

El problema de encontrar x e y tales que cumplan la relación (27) es conocido como problema de complementariedad.

Usando la notación de perpendicularidad entre vectores $\perp$, la relación de complementariedad (27) puede ser escrita de manera abreviada como:

$$0 \leq x \perp y \geq 0.$$

Remarca

Es claro que (27) es equivalente a

$$\begin{cases} x_i \geq 0, & \forall i = 1, \ldots, n \\ y_i \geq 0, & \forall i = 1, \ldots, n \\ x_i y_i = 0, & \forall i = 1, \ldots, n. \end{cases}$$

Notemos que si para algún $i \in \{1, \ldots, n\}$ se tiene que $x_i > 0$ entonces necesariamente $y_i = 0$. Es de esta propiedad que viene el término de complementariedad.

Proposición 26 Llamamos función de complementariedad Fischer Burmeister (FB) a la función $\varphi_n : \mathbb{R}^n \times \mathbb{R}^n \to \mathbb{R}^n$ definida como

$$\varphi_n(x, y) = x + y - \sqrt{x^2 + y^2}$$

Proposición 27 Sea $x, y \in \mathbb{R}^n$. Entonces se tiene que

$$0 \leq x \perp y \geq 0 \iff \varphi_n(x, y) = 0.$$

Para más detalles de la derivada generalizada revisar pag 51.

1.4. Autovalores de Pareto. El problema consiste en lo siguiente: Hallar un escalar $\lambda \in \mathbb{R}$ y un vector no nulo $x \in \mathbb{R}^n$ tal que

$$0 \leq x \perp (Ax - \lambda x) \geq 0. \tag{29}$$

El escalar λ es conocido como autovalor de Pareto y el vector x es conocido como autovector de Pareto.

Nuestra primera tarea es reformular el problema (29) como un sistema de ecuaciones. Introduciendo la variable $y = Ax - \lambda x$, el problema (29) puede escribirse como:

$$\begin{cases} Ax - \lambda x - y = 0, \\ 0 \leq x \perp y \geq 0. \end{cases} \tag{30}$$

Ahora usaremos la función de complementariedad de Fischer-Burmeister para reescribir la segunda condición de (30) como $\varphi_n(x, y) = 0$ y además añadiremos la condición $\langle x, 1 \rangle - 1 = 0$, donde $1 := (1, \ldots, 1)^T \in \mathbb{R}^n$, para garantizar que el autovector de Pareto a hallar sea no nulo. Entonces, el

problema de encontrar autovalores de Pareto equivale a resolver el siguiente sistema no lineal cuadrado de ecuaciones:

$$\begin{cases} Ax - \lambda x - y = 0, & (31) \\ \varphi_n(x, y) = 0, & (32) \\ \langle x, \mathbf{1} \rangle - 1 = 0. & (33) \end{cases}$$

Definamos $\Phi : \mathbb{R}^n \times \mathbb{R}^n \times \mathbb{R} \to \mathbb{R}^n \times \mathbb{R}^n \times \mathbb{R}$ como

$$\Phi(x, y, \lambda) = (Ax - \lambda x - y, \varphi_n(x, y), \langle x, 1 \rangle - 1),$$

entonces resolver el sistema (31)-(33) equivale a hallar (x, y, λ) tal que

$$\Phi(x, y, \lambda) = 0. \tag{34}$$

Ahora o podemos usar el método de Newton semismooth para resolver (34). Los pasos son los siguientes:

Punto inicial Generamos $\xi \in \mathbb{R}^n$ de manera aleatoria siguiendo la distribución normal. Entonces definimos:

$$x_0 = \frac{\xi}{\langle \xi, \mathbf{1} \rangle}.$$

Esto garantiza que x_0 satisfaga (33). Por otra parte, deseamos definir λ_0 e y_0 de modo que (x_0, y_0, λ_0) cumpla (31); es decir, deseamos que:

$$Ax_0 - \lambda_0 x_0 - y_0 = 0.$$

Tomando el producto interno de la ecuación anterior con respecto a x_0 tenemos que

$$\langle Ax_0, x_0 \rangle - \lambda_0 \|x_0\|^2 - \langle y_0, x_0 \rangle = 0.$$

Como queremos que se cumpla la relación de complementariedad, podemos imponer $\langle y_0, x_0 \rangle = 0$ en la última ecuación, obteniendo de este modo que:

$$\lambda_0 = \frac{\langle Ax_0, x_0 \rangle}{\|x_0\|^2}.$$

Luego tomamos

$$y_0 = Ax_0 - \lambda_0 x_0.$$

Resumiendo, el modo de tomar el punto inicial es:

$$\begin{cases} \text{Generamos aleatoriamente } \xi \in \mathbb{R}^n \text{ y definimos:} \\ x_0 = \frac{\xi}{\langle \xi, \mathbf{1} \rangle}, \\ \lambda_0 = \frac{\langle Ax_0, x_0 \rangle}{\|x_0\|^2}, \\ y_0 = Ax_0 - \lambda_0 x_0. \end{cases}$$

Iteración. La iteración es

$$(x_{k+1}, y_{k+1}, \lambda_{k+1}) = (x_k, y_k, \lambda_k) + (\Delta x, \Delta y, \Delta\lambda),$$

donde

$$V_k(\Delta x, \Delta y, \Delta\lambda) = -\Phi(x_k, y_k, \lambda_k) \tag{35}$$

con $V_k \in \partial\Phi(x_k, y_k, \lambda_k)$. Calculando $\partial\Phi(x_k, y_k, \lambda_k)$, el sistema lineal (35) tiene la forma:

$$\begin{bmatrix} A - \lambda_k I_n & -I_n & -x_k \\ E & F & 0 \\ \mathbf{1}^T & 0 & 0 \end{bmatrix} \begin{bmatrix} \Delta x \\ \Delta y \\ \Delta\lambda \end{bmatrix} = - \begin{bmatrix} Ax_k - \lambda_k x_k - y_k \\ \varphi_n(x_k, y_k) \\ \langle x_k, \mathbf{1}\rangle - 1 \end{bmatrix},$$

donde $[E, F] \in \partial\varphi_n(x_k, y_k)$.

Reglas de alto:

$$\begin{cases} \|\Phi(x_k, y_k, \lambda_k)\| < 10^{-8}, & \text{(método converge)} \\ k = 10^3, & \text{(método diverge)} \\ \operatorname{rank}(V_k) < 2n + 1, & \text{(método no definido)} \end{cases}$$

donde $\operatorname{rank}(V_k)$ es el rango de la matriz V_k y $\operatorname{rank}(V_k) < 2n + 1$ significa que V_k no es invertible.

1.5. Proyección a un cono poliedral simplicial. El cono dual de C está definido por

$$C^* := \{z \in \mathbb{R}^n : \langle z, x\rangle \geq 0, \forall x \in C\}.$$

Ejemplo 36. El octante positivo $\mathbb{R}^n_+$ es un cono convexo. Su cono dual será el mismo, es decir

$$(\mathbb{R}^n_+)^* = \mathbb{R}^n_+.$$

Pongamos nuestro enfoque en los conos poliedrales en $\mathbb{R}^n$. Se dice que P es un cono poliedral si está definido como:

$$P = \left(\sum_{i=1}^{n} \alpha_i v_i : \alpha_i \geq 0, i = 1, \ldots, \ell \right), \tag{39}$$

donde $\{u_1, \ldots, u_\ell\}$ es una colección de vectores en $\mathbb{R}^n$. Usando la matriz $M = [u_1, \ldots, u_\ell] \in \mathbb{M}_{n,\ell}$, el cono P puede ser escrito como:

$$P = M(\mathbb{R}^\ell_+).$$

Definición 37 Sea $\mathcal{U} := \{u_1, \ldots, u_n\} \subset \mathbb{R}^n$ y $M := [u_1, \ldots, u_n]$. Se dice que el cono poliedral $K = M(\mathbb{R}^n_+)$ es simplicial si el conjunto de vectores $\mathcal{U}$ forma una base para $\mathbb{R}^n$.

Proposición 38 Sea $K = M(\mathbb{R}^n_+)$ un cono poliedral simplicial con $M = [u_1, \ldots, u_n]$. Entonces

$$K^* = M^{-T}(\mathbb{R}^n_+),$$

donde M^{-T} denota la inversa de la matriz transpuesta de M.

Fomulación del Problema

Sea $C \subset \mathbb{R}^n$ un conjunto cerrado convexo no vacío, la proyección de un punto a sobre C, denotado por $\Pi_C(a)$, está definida como la solución del siguiente problema de optimización:

$$\min_{x \in C} \|x - a\|.$$

Es decir, la proyección de a sobre C es el punto de C que se encuentra a menor distancia de a.

Teorema 39 Sea $C \subset \mathbb{R}^n$ un conjunto cerrado convexo no vacío y $a \in \mathbb{R}^n$. Entonces, x es la proyección de a sobre C si y solamente si

$$x \in C, \quad \langle v - x, a - x \rangle \leq 0, \quad \forall v \in C.$$

Ahora comencemos con la formulación del problema. Sea $K = M(\mathbb{R}^n_+)$ un cono poliedral simplicial con $M = [u_1, \ldots, u_n]$. Sea $a \in \mathbb{R}^n$ un punto dado. Deseamos hallar la proyección de a sobre K.

Proposición 40 Sea $C \subset \mathbb{R}^n$ un cono convexo y cerrado de $\mathbb{R}^n$ y $a \in \mathbb{R}^n$ un punto dado. Entonces se tiene

$$x = \Pi_C(a) \text{ si y solo si } C \ni x \perp (x - a) \in C^*.$$

Ahora regresemos a nuestro problema. Recordemos que de la Proposición 38 se tiene que $K^* = M^{-T}(\mathbb{R}^n_+)$. Entonces, por la anterior proposición, para hallar la proyección de a sobre $K = M(\mathbb{R}^n_+)$ debemos hallar $x \in \mathbb{R}^n$ (la cual será la proyección) tal que satisfaga:

$$\begin{cases} x \in M(\mathbb{R}^n_+), \\ x - a \in M^{-T}(\mathbb{R}^n_+), \\ \langle x, x - a \rangle = 0. \end{cases} \tag{42}$$

Introduciendo la variable $y = x - a$, el problema (42) equivale a hallar $x, y \in \mathbb{R}^n$ tal que

$$\begin{cases} x - a - y = 0, \\ x \in M(\mathbb{R}^n_+), \\ y \in M^{-T}(\mathbb{R}^n_+), \\ \langle x, y \rangle = 0. \end{cases} \tag{43}$$

Ahora hagamos el cambio de variable $x = Mu$ y $y = M^{-T}v$. Luego se verifican las siguientes propiedades:

1. $x \in M(\mathbb{R}^n_+)$ si y solo si $u \in \mathbb{R}^n_+$.
2. $y \in M^{-T}(\mathbb{R}^n_+)$ si y solo si $v \in \mathbb{R}^n_+$.
3. $0 = \langle x, y \rangle = \langle Mu, M^{-T}v \rangle = \langle M^{-1}Mu, v \rangle = \langle u, v \rangle$.

Entonces, con dicho cambio de variable y por las propiedades anteriormente mencionadas, el problema (43) puede ser formulado de manera equivalente como:

$$\begin{cases} Mu - a - M^{-T}v = 0, \\ u \in \mathbb{R}^n_+, \\ v \in \mathbb{R}^n_+, \\ \langle u, v \rangle = 0. \end{cases} \tag{44}$$

Finalmente, como las tres últimas condiciones de (44) forman una relación de complementariedad entre u y v, entonces podemos usar la función de complementariedad de Fischer-Burmeister φ_n, consiguiendo que el problema (44) se convierta en un sistema cuadrado de ecuaciones no lineales dado por:

$$\begin{cases} Mu - a - M^{-T}v = 0, \\ \varphi_n(u, v) = 0. \end{cases} \tag{45}$$

El método para hallar la proyección de a sobre el cono poliedral simplicial $K = M(\mathbb{R}^n_+)$ se resume en el siguiente esquema:

Paso 1. Usando el método MNS, resolver el sistema

$$\begin{cases} Mu - a - M^{-T}v = 0, \\ \varphi_n(u, v) = 0 \end{cases}$$

Paso 2. Tomar $x = Mu$.
Paso 3. La proyección de a sobre K será x.

Implementación del método MNS

Punto inicial. Generamos $\xi \in \mathbb{R}^n$ de manera aleatoria siguiendo la distribución normal. Entonces definimos:

$$u_0 = \frac{\xi}{\|\xi\|}.$$

Luego, usando la primera ecuación de (45) definimos

$$v_0 = M^T(Mu_0 - a).$$

Iteración. La iteración es

$$(u_{k+1}, v_{k+1}) = (u_k, v_k) + (\Delta u, \Delta v),$$

donde

$$V_k(\Delta u, \Delta v) = -\Psi(u_k, v_k) \tag{47}$$

con $V_k \in \partial\Psi(u_k, v_k)$. Calculando $\partial\Psi(u_k, v_k)$, el sistema lineal (47) tiene la forma:

$$\begin{bmatrix} M & -M^{-T} \\ E & F \end{bmatrix} \begin{bmatrix} \Delta u \\ \Delta v \end{bmatrix} = - \begin{bmatrix} Mu_k - a - M^{-T}v_k \\ \varphi_n(u_k, v_k) \end{bmatrix},$$

donde $[E, F] \in \partial\varphi_n(u_k, v_k)$.

Reglas de alto:

$$\begin{cases} \|\Psi(u_k, v_k)\| < 10^{-8}, & \text{(método converge)} \\ k = 10^3, & \text{(método diverge)} \\ \operatorname{rank}(V_k) < 2n, & \text{(método no definido)} \end{cases}$$

donde $\operatorname{rank}(V_k)$ es el rango de la matriz V_k y $\operatorname{rank}(V_k) < 2n$ significa que V_k no es invertible.

Experimentaciones numéricas

Para ver la eficiencia de este método se hará la siguiente experimentación: 1. Generamos un cono poliedral simplicial K aleatoriamente siguiendo la distribución normal. Esto se consigue generando aleatoriamente la matriz $M \in \mathbb{M}_{n\times n}$ y tomando $K = M(\mathbb{R}^n_+)$. 2. Generamos aleatoriamente un punto $a \in \mathbb{R}^n$ siguiendo la distribución normal. 3. Usamos el método MNS para calcular la proyección de a en K.

Intervalo (π radianes)	**Porcentaje (%)**	
0	$[0.0\pi,\ 0.1\pi)$	0.0
1	$[0.1\pi,\ 0.2\pi)$	0.4
2	$[0.2\pi,\ 0.3\pi)$	1.6
3	$[0.3\pi,\ 0.4\pi)$	0.7
4	$[0.4\pi,\ 0.5\pi)$	0.6
5	$[0.5\pi,\ 0.6\pi)$	1.4
6	$[0.6\pi,\ 0.7\pi)$	28.3
7	$[0.7\pi,\ 0.8\pi)$	38.5
8	$[0.8\pi,\ 0.9\pi)$	27.2
9	$[0.9\pi,\ 1.0\pi)$	0.3

Cuadro 1. Tabla de Intervalos y Porcentajes para n = 5

Estado	**Veces n = 5**	
0	Converge	875
1	No converge	125
2	Mal condicionado (No invertible)	0
Estado	**Veces n = 10**	
0	Diverge (No invertible)	717
1	No converge (No invertible)	283
2	Mal condicionado (No invertible)	0

Cuadro 2. Tabla de número de Estados para n = 5 y n = 10, realizando 1000 iteraciones